

Desafío Técnico – IA Engineer

Caso: Sistema Multi-Agente para Detección de Fraude Ambiguo en Transacciones Financieras

1. Contexto de Negocio

Las instituciones financieras enfrentan el reto de detectar fraudes en transacciones que presentan señales ambiguas: montos inusuales, horarios no habituales, dispositivos desconocidos o patrones de comportamiento atípicos.

El objetivo de este reto es construir una **web App (Backend + Frontend)** que implemente un **Sistema Multi-Agente de Detección de Fraude**, capaz de:

- Analizar transacciones en tiempo real.
- Evaluar señales internas (comportamiento, monto, horario, país, dispositivo).
- Consultar políticas internas mediante RAG (base vectorial).
- Buscar inteligencia externa sobre amenazas recientes (búsqueda web gobernada).
- Orquestar agentes para tomar decisiones rápidas y trazables.
- Incluir revisión humana (Human-in-the-loop) cuando la decisión lo requiera.

2. Datos sintéticos

Se proporcionan datos sintéticos, sin datos personales reales:

- **Transactions**

transaction_id	customer_id	amount	currency	country	channel	device_id	timestamp	merchant_id
T-1001	CU-001	1800.00	PEN	PE	web	D-01	2025-12-17T03:15:00	M-001
T-1002	CU-002	9500.00	PEN	PE	mobile	D-02	2025-12-17T23:45:00	M-002

- **customer_behavior**

customer_id	usual_amount_avg	usual_hours	usual_countries	usual_devices
CU-001	500.00	08-20	PE	D-01
CU-002	1200.00	09-22	PE	D-02

- **fraud_policies:**

```
[
  {
    "policy_id": "FP-01",
    "rule": "Monto > 3x promedio habitual y horario fuera de rango → CHALLENGE",
    "version": "2025.1"
  },
  {
    "policy_id": "FP-02",
    "rule": "Transacción internacional y dispositivo nuevo → ESCALATE_TO_HUMAN",
    "version": "2025.1"
  }
]
```

3. Requerimientos Técnicos

Construir una **web App (Backend + Frontend)** que:

- Procese los archivos entregados y consolide la información por transacción y cliente.
- Analice señales clave: monto, horario, país, dispositivo, patrón de comportamiento.
- Genere al menos cuatro escenarios por transacción:
 - **APPROVE**: transacción legítima.
 - **CHALLENGE**: requiere validación adicional.
 - **BLOCK**: bloqueo por sospecha de fraude.
 - **ESCALATE_TO_HUMAN**: revisión humana obligatoria.
- Utilice un **equipo multi-agente** orquestado:
 - **Transaction Context Agent**: analiza señales internas.
 - **Behavioral Pattern Agent**: compara con el historial del cliente.
 - **Internal Policy RAG Agent**: consultas políticas internas vía base vectorial.
 - **External Threat Intel Agent**: busca amenazas recientes en la web (gobernada).
 - **Evidence Aggregation Agent**: reúne todas las evidencias.
 - **Debate Agents**: Pro-Fraud vs Pro-Customer.

- **Decision Arbiter Agent:** toma la decisión.
- **Explainability Agent:** genera explicación para cliente y auditoría.
- Implemente **Human-in-the-loop** con cola de casos y audit trail.
- Calcule la **confianza** y registre señales, evidencias internas (RAG) y externas (web).
- Genere un **informe explicativo en lenguaje natural** por transacción, usando IA Generativa.
- Lenguaje de programación preferente: Python.
- Despliegue en la nube (preferentemente **Azure**, se acepta **AWS**).
- Utilice frameworks de agentes/orquestación (Ejemplos: Azure AI Agent Framework, LangChain, Agent SDK, Bedrock Agents, etc.).
- Si falta información, asuma bajo su mejor criterio.

4. Criterios de Evaluación

Criterio	Puntaje
Diseño de arquitectura multiagente y orquestación	25 pts
- Claridad en la definición de roles de agentes y su interacción	
- Uso de un framework de orquestación (ej. Azure AI Agent Framework, Agent SDK, LangChain, Bedrock Agents, etc.)	
Implementación del flujo multiagente	20 pts
- Correcta secuencia y colaboración entre agentes	
- Manejo de handoffs u otro patrón y agregación de evidencias	
Integración de fuentes internas (RAG) y externas (web search)	15 pts
- Uso efectivo de RAG para políticas internas	
- Consulta de inteligencia externa relevante y gobernada	
Trazabilidad y auditabilidad del proceso de decisión	15 pts
- Registro de señales, evidencias, rutas de agentes y decisiones	
- Generación de explicaciones claras para cliente y auditoría	
Despliegue en la nube y buenas prácticas DevOps	10 pts
- Infraestructura como código, CI/CD, seguridad de secretos	
- Uso de servicios gestionados (Azure/AWS) y justificación técnica	
Documentación, presentación y claridad del README	10 pts
- Instrucciones claras de despliegue y uso	
- Ejemplos de uso, evidencia de funcionamiento y trazabilidad	
Creatividad, valor agregado y mejoras sobre lo solicitado	5 pts
- Propuestas innovadoras, visualizaciones, mejoras UX, etc.	

5. Entregables

- Repositorio en GitHub con el código fuente y README. enviar al siguiente correo: enriqueinca@bcp.com.pe. Plazo de entrega 48 horas después de recibir el desafío.
- Instrucciones de ejecución local o enlace a demo desplegada.
- Informe generado por IA para al menos 4 transacciones (cada tipo de decisión).
- Evidencia de trazabilidad y audit trail.
- (Opcional) Video corto explicando la solución (máx. 5 min).

Ejemplo de Flujo Multi-Agente

1. **Llega una transacción:** T-1002, monto 9500 PEN, horario 23:45, dispositivo D-02.
2. **Transaction Context Agent** detecta monto y horario fuera de lo habitual.
3. **Behavioral Pattern Agent** confirma que el cliente suele operar con montos menores y en otro horario.
4. **Internal Policy RAG Agent** recupera la política FP-01: "Monto > 3x promedio y horario fuera de rango → CHALLENGE".
5. **External Threat Intel Agent** encuentra alerta reciente de fraude en ese merchant vía web search gobernada.
6. **Evidence Aggregation Agent** reúne señales y evidencias.
7. **Debate Agents** discuten: Pro-Fraud (sospecha) vs Pro-Customer (historial limpio).
8. **Decision Arbiter Agent** decide: CHALLENGE.
9. **Explainability Agent** genera explicación para el cliente y auditoría, citando reglas y fuentes.
10. Si la confianza es baja o hay señales contradictorias, **ESCALATE_TO_HUMAN** y se registra en la cola HITL.

- **Formato de Respuesta por Evaluación:**

```
{
  "decision": "CHALLENGE",
  "confidence": 0.65,
  "signals": ["Monto fuera de rango", "Horario no habitual", "Alerta externa"],
  "citations_internal": [
    { "policy_id": "FP-01", "chunk_id": "1", "version": "2025.1" }
  ],
  "citations_external": [
    {
      "url": "https://<URL de referencia>",

```

```
    "summary": "Alerta de fraude reciente en el merchant"
  }
],
  "explanation_customer": "La transacción requiere validación adicional por
monto y horario inusual.",
  "explanation_audit": "Se aplicó la política FP-01 y se detectó alerta externa.
Ruta de agentes: Context → RAG → Web → Debate → Decisión."
}
```

¡Tengo la certeza de que podrás con este desafío!